Machine Learning II — Deep Learning

Clasificación automática de imágenes inmobiliarias

Javier Arroyo García Julia Cano Flores Paula Durá Fuster

Abril 2026 · ICAI

1. Introducción y contexto de negocio

En marketplaces inmobiliarios como Idealista o Zillow, la calidad y la correcta categorización visual de los anuncios influye directamente en la experiencia de los compradores y en la velocidad de venta. La categorización manual de imágenes a escala es costosa, inconsistente y no escalable: un agente inmobiliario puede subir decenas de fotos por propiedad, y clasificarlas correctamente requiere tiempo y criterio especializado.

Este proyecto desarrolla un **servicio de clasificación automática de imágenes en 15 categorías de escena** orientado a integrarse en el flujo de publicación de un marketplace. El usuario objetivo es el equipo técnico de la plataforma, que necesita una solución robusta, reproducible y con documentación suficiente para operar y mantener en producción. El valor esperado es la reducción del trabajo manual de clasificación y la mejora de la coherencia del catálogo.

Las **restricciones operativas** del entorno de producción condicionan el diseño del sistema: el servicio debe responder en tiempo real (latencia de inferencia del orden de milisegundos por imagen), debe poder ejecutarse sin GPU dedicada en escenarios de bajo coste (instancias serverless o CPU), y debe ser lo suficientemente preciso como para no requerir revisión manual sistemática.

El pipeline completo está compuesto por tres componentes:

1. Selección y comparación de modelos preentrenados mediante transfer learning
2. Experimentación trazable y búsqueda de hiperparámetros con Weights & Biases
3. Despliegue de un servicio de inferencia con FastAPI como backend y Streamlit como interfaz de usuario.

1.1. Descripción del dataset

El dataset consta de **2 985 imágenes de entrenamiento** y **1 500 de validación** repartidas en 15 categorías de escenas interiores y exteriores: *Bedroom, Coast, Forest, Highway, Industrial, Inside city, Kitchen, Living room, Mountain, Office, Open country, Store, Street, Suburb* y *Tall building*.

2. Selección de modelos y estrategia de transfer learning

2.1. Modelos candidatos

La elección de modelos se ha hecho intentando cubrir la mayor variedad posible: en lugar de comparar variantes de una misma familia, se seleccionó un representante de cada una de las tres grandes corrientes de la visión por computador moderna. De este modo, los resultados permiten extraer conclusiones sobre enfoques, no solo sobre configuraciones concretas.

- **Swin-T** representa los *Vision Transformers*. Su fortaleza reside en comprender el contexto global de una imagen: qué hay a la izquierda, qué hay al fondo, cómo se relacionan las distintas zonas de la

escena. Esto lo hace intuitivamente adecuado para imágenes inmobiliarias, donde el conjunto de la habitación importa tanto como sus elementos individuales.

- **ConvNeXt-Small** representa las redes convolucionales modernas. Es la apuesta de mayor capacidad del grupo: incorpora las lecciones aprendidas de los transformadores utilizando la arquitectura convolucional, lo que le permite ser preciso y estable. A priori, es el candidato al mejor rendimiento absoluto.
- **EfficientNetV2-S** representa los modelos orientados a eficiencia. Con menos parámetros y mayor velocidad de inferencia, es el candidato natural para producción en entornos con restricciones de latencia o coste computacional. Se incluye para verificar si la ganancia en precisión de los modelos más grandes justifica su coste adicional.

La **métrica principal** es la *val_accuracy* (proporción de predicciones correctas en validación), complementada con el **F1 macro** para detectar sesgos entre clases en un problema de 15 categorías con posible desbalance. Se considera éxito alcanzar $\geq 0{,}80$ de accuracy con curvas de entrenamiento estables (sin crecimiento sostenido del gap train/val).

2.2. Estrategia de transfer learning en dos fases

La idea central del transfer learning es no partir de cero. Los modelos ya han aprendido a reconocer formas, texturas y estructuras visuales en millones de imágenes; el objetivo es reutilizar ese conocimiento y adaptarlo a nuestro problema con el mínimo coste y riesgo posible. Para ello se aplica un esquema de dos fases progresivas, idéntico para los tres modelos.

Fase 1 — Aprender a clasificar sin tocar el modelo base (backbone congelado): en una primera etapa, el cuerpo del modelo se congela por completo y solo se entrena la capa final, que es la única parte nueva. Esta decisión tiene una lógica clara: si se intentara actualizar toda la red desde el principio, los primeros gradientes —procedentes de una cabeza sin entrenar— podrían destruir el conocimiento ya aprendido. Dejar el backbone fijo garantiza un arranque estable y permite que la cabeza se adapte a las 15 clases del problema antes de tocar nada más.

Fase 2 — Afinar las capas superiores del modelo (unfreeze de capas): una vez que la cabeza está orientada al problema, se descongelan los últimos bloques del backbone y se les permite ajustarse también, pero con mucha más cautela. Se usan tasas de aprendizaje distintas para cada parte: más alta para la cabeza (que aún tiene margen de mejora) y mucho más baja para el backbone (para no sobreescribir lo que ya funcionaba bien). El resultado es una adaptación progresiva y controlada al dominio de imágenes inmobiliarias, manteniendo la estabilidad del entrenamiento.

2.3. Resultados del baseline (fase 1, 8 épocas, AdamW, lr=1e-3)

Cuadro 1: Resultados del baseline con backbone completamente congelado.

Modelo	Acc. train	Acc. valid	Loss train	Loss valid	Tiempo/época
Swin-T	0.830	**0.911**	0.547	**0.275**	3 min 45 s
ConvNeXt-Small	0.766	0.855	1.016	0.881	5 min 18 s
EfficientNetV2-S	0.716	0.806	0.900	0.637	3 min 20 s

Swin-T lidera el baseline con 91.1 % de accuracy y la menor pérdida de validación, lo que indica que sus representaciones preentrenadas son más directamente transferibles a este dominio. Los tres modelos superan ya el criterio de éxito mínimo (80 %) con el backbone congelado, confirmando la calidad de los pesos preentrenados en ImageNet para escenas interiores.

2.4. Arquitectura de la red desplegada en el API

Los tres modelos comparten la misma estructura de red en el servicio de inferencia: un **backbone preentrenado** (ConvNeXt-Small, EfficientNetV2-S o Swin-T según el modelo seleccionado) del que se elimina la cabeza de clasificación original, seguido de una **capa** `Flatten` y una **capa lineal** (`LazyLinear`) con 15 salidas —una por categoría de escena. La inicialización perezosa de la capa lineal permite reutilizar el mismo código independientemente del tamaño del vector de características de cada backbone. Durante la inferencia, las activaciones de salida se convierten en probabilidades mediante `softmax` y se devuelven ordenadas por confianza al cliente.

3. Búsqueda sistemática de hiperparámetros

3.1. Diseño experimental y tracking en W&B

Se diseñaron tres sweeps independientes en W&B con **optimización bayesiana**, uno por modelo, ejecutando **12 runs cada uno** (36 en total) con semilla fija (42). Mantener sweeps separados garantiza el mismo presupuesto de búsqueda por arquitectura, de modo que el ranking final refleja el potencial real de cada enfoque. Por cada run se registraron métricas por época (`val/acc`, `val/f1_macro`, pérdidas y tiempo), la configuración completa y el mejor checkpoint como artefacto en W&B.

El espacio de búsqueda fue el mismo para los tres modelos:

- **lr_head**: log-uniforme en $[10^{-4}, 10^{-2}]$; **lr_backbone**: log-uniforme en $[10^{-6}, 10^{-4}]$.
- **optimizer**: AdamW o SGD (momentum 0.9); **weight_decay**: $\{0{,}001, 0{,}01, 0{,}05, 0{,}1\}$.
- **unfreeze_layers**: $\{0, 1, 2, 3\}$ bloques finales del backbone.
- **warmup_epochs**: $\{3, 5\}$; **finetune_epochs**: $\{5, 8, 10\}$.

3.2. Resultados del sweep

La Figura 1 muestra la evolución de la accuracy de validación por época para el mejor run de cada modelo. Las curvas revelan dinámicas de aprendizaje muy distintas: Swin-T arranca desde el valor más alto ($\sim$0.88) y converge en pocas épocas, pero se estanca en torno al 92 %. EfficientNetV2-S parte muy bajo ($\sim$0.45) con el backbone congelado y experimenta un salto brusco de más de 20 pp en la transición a la fase de fine-tuning ($\sim$época 5), alcanzando finalmente el 96 %. ConvNeXt-Small presenta la progresión más sostenida: arranca en $\sim$0.81 y acumula mejoras época a época hasta liderar con 96.47 %. Las tres curvas ilustran una *inversión del ranking*: Swin-T parte en cabeza y termina último, evidenciando que su ventaja inicial se diluye cuando los modelos convolucionales disponen de más épocas de ajuste.

La Tabla 2 recoge la mejor configuración encontrada para cada arquitectura.

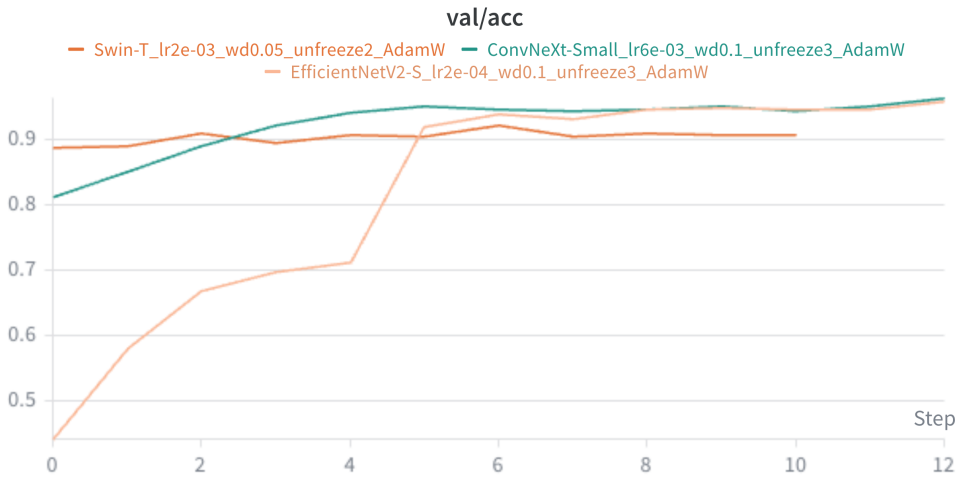

Figura 1: Curvas de val/acc por época para el mejor run de cada modelo.

Cuadro 2: Mejor configuración y métricas finales por modelo (36 runs totales).

Modelo	Val Acc	F1 Macro	s/época	Optim.	lr_head	Unfreeze
ConvNeXt-Small	**96.47 %**	**96.47 %**	99.9	AdamW	$6{,}4\times10^{-3}$	3
EfficientNetV2-S	96.00 %	96.00 %	43.5	AdamW	$1{,}8\times10^{-4}$	3
Swin-T	92.27 %	92.21 %	26.6	AdamW	$2{,}4\times10^{-3}$	2

3.3. Patrones observados

AdamW dominó de forma consistente en los tres modelos; los runs con SGD fueron hasta 17 pp peores. Descongelar *unfreeze=3* bloques fue óptimo para ConvNeXt-Small y EfficientNetV2-S (*unfreeze=2* para Swin-T), mientras que *unfreeze=0* provocó caídas de 40–80 pp, confirmando que el fine-tuning del backbone es imprescindible. `weight_decay` $\geq 0{,}05$ mejoró sistemáticamente la generalización al entrenar con datos limitados. Swin-T fue el modelo más estable entre runs (rango 88–92 %), mientras que ConvNeXt-Small y EfficientNetV2-S mostraron mayor varianza pero mayor techo de rendimiento, superando al baseline de Swin-T en cuanto se activa el fine-tuning de capas superiores.

4. Selección del modelo final y despliegue

4.1. Criterio de selección

ConvNeXt-Small se selecciona como modelo de producción principal por su mayor accuracy (96.47 %) y F1 macro (96.47 %), indicando rendimiento equilibrado en las 15 clases. La diferencia con el baseline de Swin-T (+5.4 pp) y la consistencia de las configuraciones top-4 (todas por encima del 95.8 %) refuerzan la confianza en su generalización.

EfficientNetV2-S constituye la alternativa recomendada cuando se requiere baja latencia: con un 96.00 % de accuracy y 2,3× menor tiempo por época (43.5 s vs. 99.9 s), es la opción preferible en entornos con restricciones de cómputo, como instancias serverless o despliegues sin GPU.

4.2. Arquitectura del sistema de inferencia

El servicio de inferencia en producción está compuesto por dos componentes independientes comunicados a través de HTTP:

- **Backend (FastAPI):** expone los siguientes endpoints:
  - `GET /` — health check rápido; devuelve `status` y nombre del modelo cargado.
  - `GET /health` — health check detallado; devuelve `status`, `model_loaded` y `device` (CPU/GPU).
  - `GET /classes` — devuelve la lista de las 15 categorías con su índice.
  - `GET /model-info` — devuelve metadatos del modelo: arquitectura, ruta del checkpoint, tamaño de entrada, número de clases y dispositivo.
  - `POST /predict` — recibe una imagen en base64 y devuelve la clase predicha, la confianza y el nombre de fichero.
  - `POST /predict-topk` — recibe una imagen en base64 y el parámetro `k`; devuelve las k clases más probables con sus confidencias, permitiendo al frontend mostrar la distribución completa de predicciones.

  La documentación interactiva (Swagger UI) está disponible en `/docs` y la estática en `docs/api.md`.
- **Frontend (Streamlit):** interfaz web que permite cargar imágenes locales o por URL, muestra la predicción principal con su nivel de confianza y visualiza la distribución de probabilidad sobre las 15 clases mediante gráfico de barras interactivo. Incluye un selector en la barra lateral para alternar entre ConvNeXt-Small y EfficientNetV2-S sin necesidad de reiniciar el backend, ya que ambos modelos se cargan en memoria al arranque.

4.3. Rendimiento por clase y viabilidad operativa

Al finalizar cada run, el script registra automáticamente en W&B la matriz de confusión sobre el conjunto de validación, vinculada al checkpoint y configuración exactos de ese run. Esto permite un análisis de errores trazable y reproducible.

La Tabla 3 recoge precision, recall y F1 por clase para el mejor run de ConvNeXt-Small. *Suburb* y *Office* alcanzan F1 de 1.00 y 0.99 respectivamente; *Open country* es la clase más débil (F1 = 0.88), confundiéndose principalmente con *Coast* y *Mountain* — escenas naturales sin elementos urbanos de referencia. El F1 macro de 0.96 supera ampliamente el umbral de éxito ($\geq 0{,}80$) y los errores residuales se concentran en pares de clases ambiguos incluso para un observador humano.

Cuadro 3: Métricas por clase — ConvNeXt-Small (mejor run, conjunto de validación).

Clase	Precision	Recall	F1
Bedroom	0.96	0.96	0.96
Coast	0.92	0.97	0.94
Forest	0.99	0.95	0.97
Highway	0.94	1.00	0.97
Industrial	0.98	0.98	0.98
Inside city	0.96	0.90	0.93
Kitchen	0.94	0.97	0.96
Living room	0.97	0.94	0.95
Mountain	0.99	0.97	0.98
Office	0.99	0.99	0.99
Open country	**0.90**	**0.87**	**0.88**
Store	0.96	0.99	0.98
Street	0.95	0.95	0.95
Suburb	1.00	1.00	1.00
Tall building	0.98	0.98	0.98
Macro avg	**0.96**	**0.96**	**0.96**

5. Reproducibilidad

Los experimentos se ejecutaron en Lightning AI con GPU T4 y entorno Python 3.12 gestionado con conda. El código fuente completo está disponible en `https://github.com/juliacanoflores/ImageClassification`. El repositorio incluye:

- `requirements.txt` con versiones exactas de todas las dependencias (PyTorch 2.2.1, torchvision 0.17.1, wandb 0.18.1, entre otras).
- Semilla global fija (42) aplicada a `torch`, `torch.cuda`, `numpy` y `random` antes de cada run.
- Scripts de entrenamiento (`sweep_train.py`) y lanzamiento de sweeps (`launch_sweeps.py`) con instrucciones de ejecución en el README.
- Checkpoints de los mejores modelos como artefactos versionados en W&B, accesibles desde el workspace `https://wandb.ai/javi_paula_julia/image-classification`.

6. Conclusiones y recomendaciones

El transfer learning sobre arquitecturas modernas preentrenadas permite alcanzar un **96.47 % de accuracy y F1 macro** en clasificación de imágenes inmobiliarias en 15 clases con tan solo 2 985 imágenes de entrenamiento y 36 ejecuciones experimentales. Los tres hallazgos principales del proceso de tuning son: (1) AdamW supera a SGD en todos los escenarios de fine-tuning evaluados; (2) descongelar al menos 2–3 bloques del backbone es imprescindible para superar el 92 %; y (3) weight_decay $\geq$ 0,05 mejora consistentemente la generalización cuando se entrena con datos limitados.

Recomendación operativa: desplegar ConvNeXt-Small para máxima precisión, o EfficientNetV2-S cuando la latencia o el coste de inferencia sean críticos. La diferencia de accuracy entre ambos es marginal (0.47 pp), mientras que la diferencia de coste computacional es significativa (2,3×). Para un marketplace con alto volumen de imágenes diarias, EfficientNetV2-S ofrece el mejor balance coste-beneficio.

Mejoras futuras: (1) data augmentation más agresiva (mixup, cutmix) para reducir la varianza y mejorar robustez ante imágenes atípicas; (2) ensemble de ConvNeXt-Small y EfficientNetV2-S por votación suave.